

PROJETO DE INICIAÇÃO CIENTÍFICA

Nº Projeto: PIC_PIBIC_151

Nome Edital: PIC/PIBIC - 2025

Área: Modelos Analíticos e de Simulação

Título do Projeto: Classificação de Sinais Temporais Utilizando Modelo Não Linear de ECG e Banco de dados MIT-BIH - Construção de um Pipeline com um estudo comparativo

Alunos: 22308774 - Pedro Lucas Rodrigues Greco -
rgreco.pedro@sempreceub.com

Orientador(a): 114903-Tiago Leite Pereira

Currículo Lates: <http://lattes.cnpq.br/3817905369983298>

Introdução

PROJETO DE INICIAÇÃO CIENTÍFICA

O eletrocardiograma (ECG) foi desenvolvido no início do século XX pelo fisiologista Willem Einthoven, que introduziu o termo "ECG" em 1893. Em 1902, Einthoven publicou o primeiro registro gráfico da atividade elétrica do coração utilizando um galvanômetro de corda. Por suas contribuições à eletrocardiografia, W. Einthoven recebeu o Prêmio Nobel de Fisiologia ou Medicina em 1924 (VILELA; BETTENCOURT, 2024).

O ECG funciona por meio de doze eletrodos posicionados em pontos estratégicos do tórax e dos membros. As derivações periféricas (I, II e III) comparam potenciais entre braço direito (–), braço esquerdo e perna esquerda (+), fornecendo visões no plano frontal — por exemplo, a derivação I reflete a atividade lateral do ventrículo esquerdo, enquanto a II enfatiza o fluxo inferior do septo interventricular. As derivações aumentadas (aVR, aVL, aVF) complementam esses eixos, focalizando sinais para cima, lateralmente e para baixo, respectivamente. As seis derivações precordiais (V1–V6) capturam a atividade no plano transversal: V1 e V2 captam a atividade no septo e na porção posterior do ventrículo direito, V3 e V4 captam a atividade no ápice e na porção frontal do ventrículo esquerdo, V5 e V6 captam a atividade no ventrículo lateral; cada eletrodo registra variações locais de despolarização e repolarização, fundamentais para identificar isquemia, bloqueios e arritmias (SATTAR; CHHABRA, 2024; RUDIC et al., 2014).

Apesar de essencial, a interpretação clínica do ECG apresenta desafios que impactam o tempo de diagnóstico. A engenharia manual de doze canais, além de tomar diversos minutos tanto para registro quanto para análise de cada paciente, aumenta a variabilidade interobservador e já foi apontada como fator de atraso em emergências cardíacas (JOHNSON et al., 2018). Além disso, a grande quantidade de exames diários em hospitais de grande porte pode criar “gargalos” na triagem, exigindo soluções que agilizem a detecção de padrões críticos enquanto se leva em conta a acurácia (ANSARI et al., 2023).

Para enfrentar esses desafios, diversos estudos exploram soluções que envolvem o aprendizado profundo aplicado ao ECG. Pyakillya et al. (2017) propuseram um aprendizado profundo com camadas convolucionais unidimensionais (1D-CNN) que extrai automaticamente características morfológicas e temporais do sinal bruto, reduzindo a necessidade de engenharia manual de atributos. Revisões de Ebrahimi et al. (2020) e Xiao et al. (2023) reforçam que CNNs são eficazes na captura de padrões espaciais (picos QRS, segmentos ST), enquanto RNNs/LSTM modelam dependências de longo prazo entre batimentos, embora ressaltem a importância de bases balanceadas e pré-processamento padronizado para mitigar o desequilíbrio nas classes de arritmia e a variabilidade dos dados.

Modelos dinâmicos não-lineares do ECG também têm sido investigados: Pereira (2022) utiliza osciladores de Van der Pol acoplados para simular ritmos normais e patológicos, classificando sinais por meio de dinâmica simbólica (GOIS; SAVI, 2009). A qualidade do sinal, por sua vez, pode ser avaliada automaticamente com ferramentas como o ECGAssess de Kramer et al. (2022), que normaliza e filtra as doze derivações em Python, garantindo que artefatos não prejudiquem o diagnóstico.

Inspirado na tese de Pereira (2022), este projeto propõe o desenvolvimento de um pipeline integrado para sinais de ECG portáteis, no qual as etapas de modelagem dinâmica — baseadas em osciladores de Van der Pol acoplados — são combinadas com filtros digitais, avaliação automática de qualidade do sinal e arquiteturas de redes LSTM. A abordagem visa não apenas reduzir o tempo de diagnóstico e aumentar a confiabilidade das classificações, mas também estender as técnicas validadas em modelos matemáticos de ECG simulados para sinais reais, viabilizando eletrocardiogramas portáteis mais acessíveis e precisos em ambientes clínicos e remotos (PEREIRA, 2022).

Justificativa

PROJETO DE INICIAÇÃO CIENTÍFICA

Embora o uso do eletrocardiograma (ECG) seja consolidado na prática clínica, as abordagens tradicionais de análise ainda enfrentam desafios significativos quando aplicadas a cenários de alta complexidade ou volume. O avanço recente das técnicas de aprendizado profundo ampliou as possibilidades de automação na classificação de sinais, mas a adoção clínica de tais soluções continua limitada por questões técnicas que vão além da simples acurácia dos modelos.

Uma das principais lacunas identificadas na literatura reside na falta de integração entre diferentes etapas do processamento do sinal de ECG. Muitos estudos concentram-se exclusivamente na construção de classificadores, negligenciando fatores cruciais como a qualidade dos dados de entrada, a presença de artefatos e a variabilidade intrínseca dos sinais captados em ambientes não controlados. Ferramentas como o ECGAssess, de Kramer et al. (2022), ilustram o potencial de automatizar a avaliação da qualidade do sinal, mas ainda não são amplamente integradas a pipelines completos de diagnóstico.

Além disso, embora redes neurais convolucionais (CNNs) e recorrentes (LSTM) sejam frequentemente utilizadas para modelagem morfológica e temporal dos sinais, há uma carência de estudos que combinem essas arquiteturas com abordagens baseadas em modelos matemáticos não lineares, como os propostos por Pereira (2022). Esses modelos dinâmicos simulam o comportamento fisiológico do coração e oferecem uma perspectiva complementar aos métodos puramente estatísticos, possibilitando maior interpretabilidade e sensibilidade a padrões patológicos complexos. Portanto, este projeto se justifica pela necessidade de desenvolver uma solução integrada que una diferentes paradigmas computacionais — aprendizado profundo, modelagem dinâmica e análise automatizada da qualidade do sinal — em um pipeline robusto e validado com dados reais. A proposta visa preencher um vazio existente entre soluções altamente especializadas e a realidade operacional de sistemas de saúde, oferecendo uma alternativa tecnológica mais eficaz, confiável e acessível para a triagem e o diagnóstico de arritmias cardíacas com dispositivos portáteis.

Objetivos

Desenvolvimento de um algoritmo para classificação do ciclo cardíaco, inspirado nas arquiteturas 1D-CNN de Pyakillya et al. (2017) e nos modelos dinâmicos de Pereira (2022), com o resultado esperado de simplificar e baratear o exame de eletrocardiograma com classificadores embarcados (PYAKILLYA et al., 2017; PEREIRA, 2022).

Os objetivos específicos deste projeto são:

Averiguar a necessidade de filtragem da base de dados MIT-BIH, avaliando a qualidade dos sinais segundo métricas propostas por Kramer et al. (2022), de modo a identificar artefatos e trechos de baixa confiabilidade (KRAMER et al., 2022).

Investigar e aplicar filtros digitais mais adequados para limpeza dos sinais de ECG, comparando técnicas de remoção de ruído e normalização de derivações que promovam preservação de características morfológicas críticas (ANSARI et al., 2023).

Implementar e comparar modelos de classificação, podendo incluindo em especial a técnica de dinâmica simbólica de Pereira (2022), além de arquiteturas híbridas CNN/LSTM que combinem extração espacial e modelagem temporal de batimentos (CHEN et al., 2020; OH et al., 2018; SANNINO; DE PIETRO, 2018; PEREIRA, 2022).

Validar o modelo com bases públicas e sinais reais captados pelo protótipo portátil, empregando o MIT-BIH como referência e comparando desempenho em cenários de aquisição controlada e ambulatorial, conforme recomendações de Xiao et al. (2023) para garantir generalização clínica (XIAO et al., 2023).

Investigar possíveis integrações em tempo real com o hardware desenvolvido, viabilizando processamento embarcado e feedback imediato em dispositivos portáteis, de modo a atender demandas de triagem rápida e remota em unidades de saúde (KRAMER et al., 2022; ANSARI et al., 2023).

Ao cumprir estes objetivos, espera-se não apenas reduzir o tempo e o custo do exame de ECG, mas também aumentar a confiabilidade e acessibilidade de diagnósticos cardíacos em ambientes clínicos e remotos.

Revisão da Bibliografia/Fundamentação Teórica

A história do exame de ECG é explorada no artigo de Vilela e Bettencourt (2024), onde a trajetória do desenvolvimento do exame é detalhada, com destaque para a contribuição de Willem Einthoven. Em um contexto mais recente, o uso de ferramentas de aprendizado profundo tem sido explorado para otimizar a análise dos sinais, com avanços notáveis na precisão da classificação, em especial, destacam-se melhorias no reconhecimento automático de padrões, redução de erros diagnósticos e aumento da sensibilidade e especificidade na detecção de arritmias cardíacas., como notado por Sattar e Chhabra (2024).

PROJETO DE INICIAÇÃO CIENTÍFICA

Johnson et al. (2018) discute como a inteligência artificial pode auxiliar o campo da cardiologia, abordando algoritmos com ênfase em previsão e suas aplicações tanto na cardiologia quanto em disciplinas correlatas. O artigo destaca o papel emergente do deep learning e de ferramentas não supervisionadas na medicina, ressaltando seu potencial para transformar a análise de sinais clínicos, como o ECG. Aprofundando-se nesse tema, Bizopoulos (2019) examina as vantagens e limitações do uso do deep learning na medicina, propondo aplicações clínicas específicas, incluindo ferramentas como o ECGAssess — um sistema que utiliza aprendizado profundo para análise automatizada de sinais de ECG, oferecendo suporte ao diagnóstico com base em padrões aprendidos diretamente dos dados, reduzindo a dependência de engenharia manual de atributos e ampliando a acurácia em contextos clínicos.

O uso de algoritmos para a classificação de sinais de ECG é evidenciado na pesquisa de Pyakillya (2009). Em seu artigo, Pyakillya propõe uma solução que utiliza aprendizado profundo com camadas convolucionais unidimensionais (1D-CNN), permitindo a extração de informações diretamente do sinal de ECG. Essa extração diminui a necessidade de engenharia manual de atributos, além de agilizar o processo de diagnóstico. O algoritmo pode ser utilizado para identificar padrões complexos nos sinais, classificando automaticamente tipos de arritmias ao aprender características discriminativas diretamente dos dados brutos, o que melhora a precisão e reduz o tempo de diagnóstico.

De forma semelhante, Ebrahimi et al. (2020) realizaram uma revisão abrangente sobre a aplicação de deep learning na classificação de arritmias cardíacas, enfatizando especialmente o uso de redes neurais convolucionais (CNNs) e recorrentes (RNNs). As CNNs são destacadas pelos autores por sua capacidade de extrair automaticamente características relevantes dos sinais de ECG, como picos, intervalos e variações nos sinais detectados, diminuindo a necessidade de engenharia manual de atributos. Já as RNNs, com destaque para suas variantes como LSTM (Long Short-Term Memory), são valorizadas pela habilidade de modelar sequências temporais, permitindo a análise do comportamento dinâmico dos batimentos ao longo do tempo. A revisão também aponta limitações importantes, como a variabilidade dos dados entre diferentes bases e o desequilíbrio entre classes de arritmia — um obstáculo que compromete a generalização e o desempenho dos modelos em cenários clínicos reais.

Complementando essa perspectiva, Xiao et al. (2023) reforçam e expandem as conclusões apresentadas por Ebrahimi et al. (2020) ao evidenciarem, em sua revisão sistemática, a evolução e consolidação das redes neurais profundas no contexto da análise de sinais de ECG. Os autores destacam que, além das CNNs e RNNs, diversas arquiteturas híbridas vêm sendo desenvolvidas com o objetivo de melhorar a robustez e a generalização dos modelos, sobretudo em situações clínicas reais onde os dados podem ser ruidosos ou incompletos. Xiao et al. salientam a importância de estratégias de balanceamento de classes para mitigar os efeitos do desequilíbrio entre diferentes tipos de arritmias, propondo o uso de técnicas como data augmentation, oversampling e algoritmos de custo sensível. Além disso, os autores chamam atenção para a necessidade de bases de dados amplas e bem anotadas como condição essencial para o sucesso de abordagens baseadas em deep learning, especialmente em aplicações voltadas à detecção precoce de eventos cardíacos críticos e suporte à decisão clínica.

Arritmia depende do exame de eletrocardiograma para ser identificada, o que pode ser mostrar um desafio em vista da baixa amplitude do aparelho, a complexidade e a não-linearidade do pulso elétrico medido, para a solução destas questões, Chen et al. (2020) propõe uma solução já discutida anteriormente que é a construção de um algoritmo de identificação automática de arritmia através de camadas convolucionais unidimensionais, e se utilizando da validação cruzada para garantia da acurácia da classificação.

Oh et al. (2018) complementam a abordagem proposta por Chen et al. (2020) ao incorporarem, em seu modelo, a arquitetura LSTM, uma variante de rede neural recorrente especializada na captura de dependências temporais de longo prazo em séries de dados, como já mencionado, como os sinais de ECG. Enquanto Chen se concentra nas camadas convolucionais unidimensionais (1D-CNN) para extrair características locais e morfologias específicas do sinal eletrocardiográfico, Oh avança ao integrar essa extração com a habilidade das LSTM para modelar a dinâmica temporal dos batimentos cardíacos, promovendo uma análise mais contextualizada do padrão cardíaco ao longo do tempo. Essa combinação fortalece a proposta de modelos híbridos para a detecção automática de arritmias, ampliando a capacidade dos algoritmos em lidar com variações sutis e sequências irregulares, características comuns nos registros reais de ECG.

Ansari et al. (2023), além de complementar os pontos apresentados por Ebrahimi et al. (2020) e Xiao et al. (2023), também trazem uma perspectiva com foco em pesquisas futuras no campo da classificação de arritmias cardíacas utilizando deep learning. Em seu artigo, os autores discutem os avanços e limitações das abordagens atuais, destacando a importância de seguir inovando nas técnicas utilizadas para melhorar a precisão e robustez dos modelos de classificação.

Uma das principais sugestões de Ansari et al. é o aprimoramento da capacidade de generalização dos modelos, que muitas vezes enfrentam dificuldades em lidar com dados de ECG provenientes de diferentes populações ou ambientes clínicos. Isso é particularmente relevante quando se considera que muitos modelos atuais tendem a ser treinados com conjuntos de dados limitados (ANSARI et al., 2023), o que pode levar a um desempenho insatisfatório em contextos do mundo real. Os autores sugerem, então, que se explorem mais abordagens de pré-processamento de dados, como a normalização e a harmonização dos sinais, para reduzir a variabilidade nos dados de treinamento e melhorar a

PROJETO DE INICIAÇÃO CIENTÍFICA

aplicabilidade dos modelos em cenários clínicos variados.

Além disso, Ansari et al. (2023) apontam a necessidade de uma maior utilização de abordagens híbridas, que combinem redes neurais convolucionais (CNNs) com redes neurais recorrentes (RNNs) e suas variantes, como LSTM. Eles ressaltam que essas abordagens híbridas oferecem uma melhor captura das características espaciais e temporais dos sinais de ECG, sendo particularmente eficazes na análise de sequências temporais e na extração de padrões complexos dos dados. Essa combinação de arquiteturas é vista como um caminho promissor para a superação das limitações encontradas nas abordagens unidimensionais, que podem não capturar de forma tão eficaz a dinâmica temporal dos sinais cardíacos.

Em relação ao trabalho de Xiao et al. (2023), que já mencionaram a importância de bases de dados robustas e estratégias de balanceamento de classes, Ansari et al. (2023) vão além e sugerem que futuras pesquisas se concentrem no desenvolvimento de bases de dados mais diversificadas e representativas, que incluam diferentes tipos de arritmias e características individuais dos pacientes. Eles também indicam que mais estudos sobre as técnicas de melhoramento de dados (data augmentation) podem ser cruciais para enfrentar o problema do desequilíbrio entre classes, uma questão que, conforme os autores, ainda representa um desafio considerável na área.

Outro ponto importante que Ansari et al. (2023) destacam é a necessidade de maior explicabilidade nos modelos de deep learning. Eles observam que, embora as redes neurais profundas sejam extremamente poderosas na classificação de sinais de ECG, há uma falta de transparência sobre como essas redes chegam a suas conclusões. Isso pode se mostrar um notável obstáculo em contextos clínicos, onde a legibilidade dos resultados é essencial para a tomada de decisões médicas. Nesse sentido, os autores sugerem que os futuros modelos devem ser desenvolvidos com uma maior ênfase em técnicas de explicabilidade, que possam fornecer aos profissionais de saúde maior compreensão sobre as razões pelas quais um diagnóstico específico foi feito.

A proposta de Pereira (2022) é complementada por outros estudos que buscam aprimorar a análise e a classificação dos sinais de ECG, com destaque para a normalização e o pré-processamento dos dados. Nesse contexto, a pesquisa de Kramer (2022) sobre a normalização das 12 derivações do ECG é crucial, pois visa ajustar a variabilidade dos sinais, um desafio frequente no uso de modelos de deep learning.

A normalização é um passo importante para garantir que os sinais sejam interpretados de forma consistente, reduzindo os efeitos da variação entre diferentes pacientes e condições de captura. Além disso, o uso da linguagem Python para implementar essa normalização proporciona uma abordagem acessível e reutilizável para a preparação dos dados. A combinação desses esforços, como o de Kramer, que visa estabilizar e uniformizar os sinais, com a análise dinâmica dos modelos de osciladores de Van der Pol acoplados proposta por Pereira (2022), possibilita uma avaliação mais robusta e precisa dos sinais de ECG. Isso cria uma ponte entre a modelagem matemática e as ferramentas computacionais aplicadas à análise do ECG, favorecendo não apenas a classificação dos sinais, mas também oferecendo uma base sólida para futuras implementações de algoritmos de deep learning. A metodologia de Kramer contribui para o aprimoramento da etapa de pré-processamento dos dados, tornando-a mais confiável, enquanto o modelo de Pereira complementa a análise com uma abordagem matemática mais detalhada, focada na dinâmica dos sinais. Dessa forma, a sinergia entre as técnicas de normalização e a modelagem matemática tem o potencial de elevar a precisão e a eficiência dos sistemas de diagnóstico automatizado de arritmias.

Inspirado em Pereira (2022), este estudo busca aprofundar a aplicação dos métodos propostos em sinais reais de ECG, propondo uma abordagem complementada por algoritmos de natureza híbrida.

Método

PROJETO DE INICIAÇÃO CIENTÍFICA

O presente estudo estrutura-se como uma investigação comparativa de métodos de classificação de sinais temporais de ECG, focalizando duas abordagens principais: redes LSTM e o método dinâmico simbólico proposto por Pereira (2022).

No levantamento e pré-processamento dos dados, serão analisados os registros do MIT-BIH Arrhythmia Database para avaliar a presença de artefatos de alta e baixa frequência. Caso identificados, serão aplicados filtros digitais conforme padronização proposta por Kramer et al. (2022), garantindo a preservação de componentes morfológicos críticos.

O estudo da arquitetura LSTM, será conduzido com o intuito de definir a topologia LSTM mais adequada para sinais de ECG, testando variações no número de camadas, neurônios e parâmetros de regularização. As configurações serão inspiradas nas práticas recomendadas por Ebrahimi et al. (2020) e Xiao et al. (2023), visando otimizar a captura de dependências temporais de longo prazo.

Implementação dos algoritmos deverá ser feita em Python, o modelo LSTM ajustado e o método de dinâmica simbólica de Pereira (2022), incluindo todos os procedimentos de treinamento, validação cruzada e ajuste de parâmetros.

Definição de métricas de avaliação Para mensurar o desempenho, serão adotadas métricas de acurácia, sensibilidade, especificidade e F1-score, conforme sugerido por Ansari et al. (2023), assegurando avaliação balanceada das classes de arritmia.

Comparação e análise dos resultados dos dois métodos serão comparados estatisticamente, identificando vantagens e limitações em termos de precisão, robustez a ruídos e custo computacional.

Conclusão dos algoritmos por fim, será elaborada uma análise crítica que determine o método mais eficaz para classificação de ECG portáteis, orientando futuras integrações em hardware embarcado e aplicações clínicas em tempo real.

Dessa forma, este protocolo metodológico permite avaliar rigorosamente a aplicabilidade das arquiteturas LSTM e dinâmicas simbólicas em dados reais de ECG, contribuindo para o desenvolvimento de pipelines integrados mais eficientes e acessíveis.

Resultados Esperados

Espera-se que o pipeline integrado seja capaz de classificar corretamente sinais reais de ECG captados tanto em condições controladas quanto em ambiente ambulatorial, atingindo métricas de desempenho comparáveis aos melhores resultados da literatura (acurácia = 90 %, sensibilidade e especificidade acima de 85 %) conforme padrões estabelecidos por Pyakillya et al. (2017) e Xiao et al. (2023). Em particular:

A aplicação de filtros digitais e avaliação automática de qualidade de sinais (Kramer et al., 2022) deverá reduzir de maneira significativa a incidência de falsos positivos/negativos causados por interferências, mantendo a integridade dos picos QRS e segmentos ST, essenciais para a classificação.

O modelo LSTM, ajustado segundo insights de Ebrahimi et al. (2020), deve demonstrar capacidade de capturar dependências de longo prazo entre batimentos, diferenciando corretamente arritmias comuns e raras mesmo em casos de desequilíbrio entre classes.

A validação cruzada no MIT-BIH e em coletas de protótipos portáteis deverá comprovar a generalização clínica da abordagem, evidenciando desempenho estável em distintos cenários de aquisição.

Comparação com dinâmica simbólica a comparação com o método de Pereira (2022) permitirá quantificar ganhos em precisão e tempo de processamento, destacando vantagens de cada técnica nos diferentes estágios do pipeline.

Será elaborada documentação completa do algoritmo que é submetido um artigo científico a periódico indexado, detalhando metodologia, ajustes de parâmetros, resultados quantitativos e discussão de implicações clínicas, cumprindo o objetivo de disseminar o avanço para a comunidade acadêmica e técnica.

Cronograma

Atividade	Data Início	Data Fim
Estudo da literatura do projeto	ago/2025	ago/2025

PROJETO DE INICIAÇÃO CIENTÍFICA

Leitura de base de dados e estudo de pré-processamento de sinais	set/2025	set/2025
implementação de algoritmos de filtragem	out/2025	out/2025
Remoção de artefatos de segmentação e validação manual de sinais	nov/2025	nov/2025
Desenvolvimento de Algoritmo para extração de atributos do sinal	dez/2025	dez/2025
Estudo de transformadas e criação de vetores de características	jan/2026	jan/2026
Implementação de modelos supervisionados e divisão dos dados	fev/2026	fev/2026
Aplicação de técnicas de validação e ajuste de hiperparâmetros	mar/2026	mar/2026
Avaliação do desempenho do modelo	abr/2026	abr/2026
Realização de testes entre os modelos implementados e discussão dos erros cometidos pelos classificadores.	mai/2026	mai/2026
Reavaliação de etapas anteriores a fim de refinar o modelo final.	jun/2026	jun/2026
Elaboração do relatório, preparação de artigo para submissão e apresentação dos resultados	jul/2026	jul/2026

Plano de Trabalho - Pedro Lucas Rodrigues Greco

Currículo Lattes do Aluno: <https://lattes.cnpq.br/2158461900091862>

1. Atividades Iniciais (Agosto – Setembro/2025):

Participação em reuniões de alinhamento e capacitação com o professor orientador.

Estudo aprofundado da literatura científica sobre sinais de ECG e algoritmos de classificação supervisionada (SVM, Random Forest, Redes Neurais, etc.).

Leitura de bases de dados públicas (como Physionet) e compreensão do formato dos dados (amostragem, canais, anotações).

Estudo sobre pré-processamento de sinais biomédicos (remoção de ruído, normalização, filtragem).

2. Implementação do Pré-Processamento dos Sinais (Outubro – Novembro/2025):

Implementação de rotinas em Python para filtragem dos sinais de ECG (filtros passa-baixa, notch e passa-alta).

Aplicação de transformações para remoção de artefatos e segmentação de batimentos.

Validação manual de alguns exemplos com auxílio do orientador para aferir a eficácia dos métodos.

3. Extração de Características (Dezembro/2025 – Janeiro/2026):

Desenvolvimento de algoritmos para extração de atributos do sinal como: duração dos intervalos PR, QRS, QT; frequência cardíaca; morfologia das ondas P, QRS e T.

Estudo de transformadas (Wavelet, Fourier) para extração no domínio da frequência.

Criação de vetores de características e análise estatística preliminar das classes.

4. Desenvolvimento e Treinamento dos Modelos (Fevereiro – Abril/2026):

Implementação de modelos supervisionados utilizando scikit-learn e TensorFlow.

PROJETO DE INICIAÇÃO CIENTÍFICA

Divisão dos dados em conjuntos de treinamento, validação e teste.

Aplicação de técnicas de validação cruzada e ajuste de hiperparâmetros.

Avaliação de desempenho dos modelos com métricas como acurácia, precisão, revocação e F1-score.

5. Validação e Consolidação dos Resultados (Maio – Junho/2026):

Realização de testes comparativos entre os modelos implementados.

Discussão crítica dos erros cometidos pelos classificadores.

Reavaliação de etapas anteriores, se necessário, para refinar o modelo final.

6. Divulgação Científica e Relatórios (Julho/2026):

Redação do relatório final de iniciação científica conforme orientações do CEUB.

Preparação de artigo para submissão em eventos acadêmicos da área de tecnologia em saúde.

Apresentação oral dos resultados no seminário institucional do CEUB (quando convocado).

Organização dos códigos, documentação e banco de dados utilizados.

Referências

PROJETO DE INICIAÇÃO CIENTÍFICA

ANSARI, Y.; ABOU, O.; QARAQE, K. A.; et al. Deep learning for ECG arrhythmia detection and classification: an overview of progress for period 2017–2023. *Frontiers in Physiology*, v. 14, 2023. Disponível em: <https://www.ncbi.nlm.nih.gov/pmc/articles/PMC10542398/>. Acesso em: 5 maio 2025.

BIZOPOULOS, P.; KOUTSOURIS, D. Deep learning in cardiology. *IEEE Reviews in Biomedical Engineering*, v. 12, p. 168–193, 2019.

CHEN, C.; HUA, Z.; ZHANG, R.; et al. Automated arrhythmia classification based on a combination network of CNN and LSTM. *Biomedical Signal Processing and Control*, v. 57, p. 101819, 2020.

EBRAHIMI, Z.; LONI, M.; DANESHTALAB, M.; et al. A review on deep learning methods for ECG arrhythmia classification. *Expert Systems with Applications: X*, v. 7, p. 100033, 2020.

GOIS, S. R.; SAVI, M. A. An analysis of heart rhythm dynamics using a three-coupled oscillator model. *Chaos, Solitons & Fractals*, v. 41, n. 5, p. 2553–2565, 2009.

JOHNSON, K. W.; TORRES SOTO, J.; GLICKSBERG, B. S.; et al. Artificial intelligence in cardiology. *Journal of the American College of Cardiology*, v. 71, n. 23, p. 2668–2679, 2018. Disponível em: <http://www.onlinejacc.org/content/71/23/2668>. Acesso em: 5 maio 2025.

KRAMER, L.; et al. ECGAssess: a Python-based toolbox to assess ECG lead signal quality. *Frontiers in Digital Health*, v. 4, 2022. Disponível em: <https://doi.org/10.3389/fdgth.2022.847555>. Acesso em: 5 maio 2025.

OH, S. L.; NG, E. Y. K.; TAN, R. S.; et al. Automated diagnosis of arrhythmia using combination of CNN and LSTM techniques with variable length heart beats. *Computers in Biology and Medicine*, v. 102, p. 278–287, 2018.

PEREIRA, T. L. Análise dinâmica a partir de um modelo não-linear para o eletrocardiograma e estudo sobre a classificação de patologias utilizando dinâmica simbólica. 2022. Tese (Doutorado em Engenharia Mecânica) – Universidade de Brasília, Brasília, 2022.

PYAKILLYA, B.; KAZACHENKO, N.; MIKHAILOVSKY, N. Deep learning for ECG classification. *Journal of Physics: Conference Series*, v. 913, p. 012004, 2017.

RUDIC, B.; et al. Short QT syndrome – review of diagnosis and treatment. *Arrhythmia & Electrophysiology Review*, v. 3, n. 2, p. 76, 2014. Disponível em: <https://www.ncbi.nlm.nih.gov/pmc/articles/PMC4711567/>. Acesso em: 30 set. 2019.

SANNINO, G.; DE PIETRO, G. A deep learning approach for ECG-based heartbeat classification for arrhythmia detection. *Future Generation Computer Systems*, v. 86, p. 446–455, 2018.

SATTAR, Y.; CHHABRA, L. Electrocardiogram. *National Library of Medicine*, 2023. Disponível em: <https://www.ncbi.nlm.nih.gov/books/NBK549803/>. Acesso em: 5 maio 2025.

VILELA, E. M.; BETTENCOURT, N. Cem anos do Prêmio Nobel na eletrocardiografia: uma tecnologia ainda essencial e preparada para o próximo século. *Arquivos Brasileiros de Cardiologia*, v. 121, n. 8, 2024.

XIAO, Q.; LEE, K.; MOKHTAR, S. A.; et al. Deep learning-based ECG arrhythmia classification: a systematic review. *Applied Sciences*, v. 13, n. 8, p. 4964, 2023. Disponível em: <https://www.mdpi.com/2076-3417/13/8/4964>. Acesso em: 5 maio 2025.

Recursos Materiais

Espaço Físico: Interno

PROJETO DE INICIAÇÃO CIENTÍFICA

Material	Marca	Produto Equivalente	Quant.	Custo Und.	Custo Total
Processamento de Dados em Nuvem	Processamento em máquina virtual		1.00 ano	R\$500.00	R\$500.00
Valor:					R\$500.00

Animais/CEUA

O Projeto não envolve pesquisa com animais de laboratório.