

Base Técnica do Projeto Classificação de Sinais de ECG com MIT-BIH

Tiago Leite Pereira

5 de abril de 2026

Resumo

Este documento consolida a base técnica do projeto de classificação de sinais de eletrocardiograma (ECG) desenvolvido sobre a MIT-BIH Arrhythmia Database. O objetivo do texto não é apenas registrar tarefas executadas, mas explicitar a formulação do problema, as decisões metodológicas já implementadas, o fluxo de dados, as representações extraídas do sinal e o protocolo de avaliação usado até o momento. O documento foi estruturado como base de manuscrito científico, de modo que possa evoluir para introdução, metodologia, resultados e discussão de um artigo completo.

Sumário

1	Propósito do manuscrito	3
2	Problema de pesquisa	3
3	Base de dados	3
3.1	MIT-BIH Arrhythmia Database	3
3.2	Estrutura dos dados no repositório	4
4	Pergunta metodológica central	4
5	Arquitetura do pipeline	4
5.1	Organização geral	4
5.2	Pontos de entrada	5
6	Metodologia implementada	5
6.1	Ingestão e tabularização	5
6.2	Pré-processamento do sinal	5
6.3	Deteção de picos R	6
6.4	Construção do dataset por batimento	6
6.5	Mapeamento de classes	6
6.6	Descritores extraídos	7
6.6.1	Descritores morfológicos	7
6.6.2	Descritores de dinâmica simbólica	7
6.6.3	Descritores RR	7
6.7	Modelo baseline atual	8

7	Protocolo de avaliação	8
7.1	Split por registro	8
7.2	Métricas de classificação	8
7.3	Métricas para detecção de picos	9
8	Estado experimental atual	9
8.1	Resultados do baseline clássico	9
8.2	Resultados da avaliação de picos R	9
9	Interpretação metodológica do estado atual	10
10	Limitações atuais	11
11	Como este texto pode evoluir para artigo	11
12	Próximos passos recomendados	11
13	Comandos de reprodução	12
13.1	Ambiente	12
13.2	Pipeline principal	12
13.3	Avaliação da detecção de picos	12
13.4	Testes	12
13.5	Compilação deste documento	12

1 Propósito do manuscrito

Este texto serve como base técnica para um futuro artigo científico. Por isso, ele foi organizado para responder de forma objetiva quatro perguntas centrais:

1. qual problema está sendo atacado;
2. quais dados e representações estão sendo usados;
3. como o pipeline atualmente implementado transforma sinal bruto em decisão de classe;
4. quais evidências experimentais já existem e quais lacunas permanecem abertas.

Em vez de funcionar apenas como relatório operacional, o documento busca capturar a lógica científica do projeto: hipóteses implícitas, escolhas de modelagem, protocolo de validação e riscos metodológicos.

2 Problema de pesquisa

O problema geral consiste em classificar batimentos cardíacos a partir de sinais de ECG, tomando como base registros anotados da MIT-BIH Arrhythmia Database. O repositório foi organizado para sustentar duas linhas metodológicas complementares:

- uma linha baseada em dinâmica simbólica e descritores não lineares;
- uma linha baseada em modelos temporais orientados por dados, com ênfase inicial em LSTM e extensões do tipo CNN/LSTM.

No estado atual do projeto, a trilha mais madura é o baseline clássico por batimento, apoiado por atributos morfológicos, atributos simbólicos e descritores de intervalo RR.

3 Base de dados

3.1 MIT-BIH Arrhythmia Database

O conjunto de dados de referência utilizado no projeto é a MIT-BIH Arrhythmia Database. No repositório, os dados brutos estão organizados em `data/raw/mit_bih/`. Cada registro contém pelo menos:

- o traçado do ECG em um ou mais canais;
- metadados do registro;
- anotações de eventos cardíacos, incluindo a localização amostral dos batimentos.

O pipeline usa taxa de amostragem de 360 Hz, conforme parametrização atual do projeto.

3.2 Estrutura dos dados no repositório

Os dados são organizados em três camadas:

Camada	Função
<code>data/raw/mit_bih/</code>	arquivos originais da base MIT-BIH em formato WFDB;
<code>data/interim/signal_tables/</code>	tabelas tabulares em CSV dos sinais e das anotações;
<code>data/processed/</code>	sinais processados, features agregadas e datasets derivados.

Essa separação favorece reprodutibilidade, inspeção intermediária e reaproveitamento das etapas do pipeline.

4 Pergunta metodológica central

No núcleo do projeto, a seguinte pergunta guia a implementação atual:

Como representar batimentos de ECG de forma suficientemente informativa para distinguir padrões fisiológicos e arritmias, preservando reprodutibilidade experimental e capacidade de comparação entre abordagens clássicas e modelos temporais?

O pipeline hoje implementado responde a essa pergunta decompondo o problema em quatro etapas:

1. preparação e limpeza do sinal;
2. localização de batimentos ou uso das anotações como referência estrutural;
3. extração de descritores por batimento;
4. treinamento e avaliação de classificadores.

5 Arquitetura do pipeline

5.1 Organização geral

O pacote principal do projeto está em `src/ecg_classification/` e foi dividido em seis blocos:

- **io**: leitura de sinais, anotações e exportação para CSV;
- **preprocessing**: limpeza, normalização e correção de baseline;
- **segmentation**: detecção de picos R e utilidades de segmentação;
- **features**: construção de descritores simbólicos, morfológicos e RR;
- **models**: modelos clássicos e scaffolds para redes neurais;
- **evaluation**: métricas, splits por registro e avaliação de detecção de picos.

5.2 Pontos de entrada

Os scripts principais atualmente disponíveis são:

```
python scripts/make_dataset.py
python scripts/preprocess_mitbih.py
python scripts/extract_symbolic_features.py
python scripts/train_classical_ml.py
python scripts/evaluate_rpeak_detection.py
```

O projeto também possui um despachante de execução:

```
python scripts/run_experiment.py make_dataset
python scripts/run_experiment.py preprocess
python scripts/run_experiment.py symbolic_features
python scripts/run_experiment.py train_classical_ml
python scripts/run_experiment.py train_lstm
```

6 Metodologia implementada

6.1 Ingestão e tabularização

A etapa de ingestão transforma os registros WFDB em tabelas CSV. Para cada registro, o projeto exporta:

- um arquivo `_record.csv` com os canais do ECG;
- um arquivo `_annotation.csv` com as colunas de amostra e símbolo anotado.

Essa decisão reduz o acoplamento com o formato nativo do WFDB durante as etapas de exploração, depuração e engenharia de atributos.

6.2 Pré-processamento do sinal

O pré-processamento atual segue uma sequência simples e reproduzível:

1. seleção do canal principal do registro;
2. limpeza do ECG com `nk.ecg_clean` do NeuroKit2;
3. remoção de baseline wander por decomposição wavelet;
4. salvamento das versões `raw`, `cleaned`, `baseline` e `baseline_corrected`.

Em termos metodológicos, essa etapa busca reduzir contaminação de baixa frequência e tornar a representação dos batimentos mais estável para segmentação e extração de features.

6.3 Detecção de picos R

A detecção de picos R atualmente é implementada com `nk.ecg_peaks` do NeuroKit2. O projeto trata essa etapa como componente metodológico crítico por dois motivos:

- erros na localização do pico deslocam a janela do batimento e degradam as features extraídas;
- a qualidade da detecção afeta diretamente qualquer pipeline que dependa de janelas centradas no batimento.

Por isso, foi adicionada uma rotina específica de avaliação da detecção, comparando picos detectados com as anotações de referência da base.

6.4 Construção do dataset por batimento

O dataset supervisionado por batimento é gerado a partir das anotações da base. Para cada batimento válido:

1. identifica-se a amostra anotada como pico de referência;
2. extrai-se uma janela com 100 amostras à esquerda e 150 à direita;
3. descartam-se casos que ultrapassem as bordas do sinal;
4. associa-se ao batimento seu rótulo e seus descritores.

Essa janela corresponde a 250 amostras por batimento, o que equivale a aproximadamente 694 ms em 360 Hz.

6.5 Mapeamento de classes

Antes do treinamento do baseline clássico, os símbolos originais da MIT-BIH são filtrados para manter apenas rótulos de batimento e depois mapeados para o esquema AAMI:

- N: batimentos normais e variantes próximas;
- S: batimentos supraventriculares;
- V: batimentos ventriculares;
- F: fusão;
- Q: batimentos não classificáveis ou associados a marcações específicas.

Essa padronização é importante para comparabilidade com literatura e para reduzir a fragmentação excessiva das classes.

6.6 Descritores extraídos

6.6.1 Descritores morfológicos

Para cada janela de batimento, o projeto extrai atualmente cinco descritores morfológicos simples:

- média;
- desvio-padrão;
- valor máximo;
- valor mínimo;
- amplitude pico-a-pico.

Esses atributos servem como baseline de baixa complexidade e oferecem uma representação resumida da forma do batimento.

6.6.2 Descritores de dinâmica simbólica

O componente simbólico hoje implementado segue a seguinte lógica:

1. normalização do sinal por z-score;
2. partição do intervalo normalizado em quatro bins;
3. simbolização do sinal com base nesses bins;
4. formação de palavras simbólicas de tamanho 3;
5. cálculo de entropia de Shannon e estatísticas derivadas.

Os atributos simbólicos atualmente computados são:

- entropia simbólica;
- número de palavras distintas;
- média dos símbolos;
- desvio-padrão dos símbolos.

Do ponto de vista científico, essa representação busca capturar padrões de complexidade e organização do traçado para além de estatísticas de amplitude.

6.6.3 Descritores RR

Para cada batimento, o projeto calcula:

- **rr_prev**: intervalo até o batimento anterior;
- **rr_next**: intervalo até o batimento seguinte.

Esses atributos incorporam contexto temporal local, que é relevante para discriminar arritmias mesmo quando a morfologia isolada do batimento não é suficiente.

6.7 Modelo baseline atual

O baseline mais consolidado do repositório utiliza um pipeline com:

- padronização via `StandardScaler`;
- classificador `BalancedRandomForestClassifier` quando `imbalanced-learn` está disponível;
- alternativa com `RandomForestClassifier` e ponderação de classes quando a dependência não está presente.

Foram definidos 300 estimadores, com ênfase explícita em lidar com desbalanceamento entre classes.

7 Protocolo de avaliação

7.1 Split por registro

O pipeline adota separação por registro, e não por batimento aleatório. Essa escolha é metodologicamente importante porque reduz vazamento de informação entre treino e teste, já que batimentos do mesmo paciente ou registro tendem a compartilhar padrões muito próximos.

No código atual, a divisão está parametrizada como:

- treino: 70%;
- validação: 15%;
- teste: 15%.

Na rotina de treinamento do baseline clássico, o desempenho reportado atualmente usa treino e teste por registro.

7.2 Métricas de classificação

As métricas atualmente computadas para o classificador são:

- *accuracy*;
- *precision* macro;
- *recall* macro;
- *F1* macro;
- matriz de confusão.

O uso de médias macro é especialmente relevante neste contexto, pois evita que classes majoritárias dominem completamente a leitura do desempenho.

7.3 Métricas para detecção de picos

Para a detecção de picos R, o projeto implementa pareamento entre picos detectados e picos anotados com tolerância fixa. Dado um conjunto de verdade de referência e um conjunto de picos detectados, são computados:

$$\text{Precision} = \frac{TP}{TP + FP} \quad (1)$$

$$\text{Recall} = \frac{TP}{TP + FN} \quad (2)$$

$$\text{F1} = \frac{2 \cdot \text{Precision} \cdot \text{Recall}}{\text{Precision} + \text{Recall}} \quad (3)$$

Também são calculados erro absoluto médio e erro absoluto mediano, em amostras e em milissegundos, para os pares corretamente associados.

8 Estado experimental atual

8.1 Resultados do baseline clássico

O arquivo `reports/tables/classical_ml_metrics.json` registra, no estado atual do projeto, os seguintes valores:

Métrica	Valor
Accuracy	0.7543
Precision macro	0.3807
Recall macro	0.3845
F1 macro	0.3713

Tabela 2: Desempenho atual do baseline clássico por batimento.

Esses números indicam que o classificador já consegue capturar parte do padrão global, mas ainda apresenta limitações importantes quando observado sob métricas macro. Em outras palavras, o *accuracy* isolado não descreve adequadamente o desempenho em classes minoritárias.

8.2 Resultados da avaliação de picos R

A nova rotina de avaliação da detecção de picos produziu os seguintes valores médios globais, com tolerância de 15 amostras:

Métrica	Valor
Precision	0.9490
Recall	0.9581
F1	0.9523

Tabela 3: Médias globais da detecção de picos R.

Os registros com pior desempenho observado até o momento foram:

Registro	F1
207	0.1546
108	0.7117
113	0.7753

Tabela 4: Registros mais críticos na detecção de picos R.




Figura 1: Desempenho da detecção de picos R por registro.

Esse resultado sugere que o componente de detecção, em termos médios, está suficientemente estável para sustentar análises posteriores, mas há registros específicos com comportamento patológico que precisam ser estudados individualmente.

9 Interpretação metodológica do estado atual

Até o momento, o projeto já estabeleceu uma base experimental coerente:

- os dados foram reorganizados em pipeline reproduzível;
- a extração de features por batimento já está operacional;
- o baseline clássico já fornece uma linha de comparação;

- a detecção de picos passou a ser avaliada explicitamente, e não assumida como perfeita.

Esse ponto é importante para o artigo futuro: a qualidade da etapa de segmentação não pode ser tratada como detalhe de implementação, mas como parte da validade interna do estudo.

10 Limitações atuais

Apesar de a base técnica estar bem encaminhada, há limitações claras no estado atual:

- o conjunto de atributos morfológicos ainda é simples;
- a etapa de split por registro ainda não explora validação cruzada;
- os resultados de LSTM e CNN/LSTM ainda não estão consolidados;
- a análise dos registros problemáticos na detecção de picos ainda não foi formalizada;
- ainda não há seção de revisão bibliográfica nem comparação com trabalhos relacionados.

11 Como este texto pode evoluir para artigo

O documento atual já pode ser expandido para um manuscrito completo com a seguinte correspondência:

Seção futura do artigo	Base já existente neste documento
Introdução	problema de pesquisa, motivação e objetivo geral;
Materiais e métodos	base de dados, pipeline, features, modelo e métricas;
Resultados	tabelas atuais de desempenho e figura da detecção de picos;
Discussão	interpretação metodológica e limitações;
Conclusão	consolidação dos achados e próximos passos.

12 Próximos passos recomendados

Para aproximar o projeto de um artigo científico robusto, os próximos passos mais importantes são:

1. investigar qualitativamente os registros com pior detecção de picos, em especial o registro 207;
2. expandir o conjunto de atributos morfológicos e temporais;
3. consolidar experimentos com modelos recorrentes;
4. acrescentar seção de trabalhos relacionados e justificar as escolhas metodológicas frente à literatura;
5. registrar protocolos experimentais comparáveis entre abordagens clássicas e profundas.

13 Comandos de reprodução

13.1 Ambiente

```
python -m venv .venv
source .venv/bin/activate
pip install --upgrade pip
pip install -r requirements.txt
pip install -r requirements-dev.txt
```

13.2 Pipeline principal

```
python scripts/make_dataset.py
python scripts/preprocess_mitbih.py
python scripts/extract_symbolic_features.py
python scripts/train_classical_ml.py
```

13.3 Avaliação da detecção de picos

```
MPLCONFIGDIR=/tmp/matplotlib .venv/bin/python scripts/evaluate_rpeak_detection.py
```

13.4 Testes

```
pytest -q
```

13.5 Compilação deste documento

```
cd reports/manuscript
pdflatex project_report.tex
pdflatex project_report.tex
```